



Universidad Nacional Autónoma de México
Facultad de Ingeniería

Pronóstico y clasificación

Enfoques de aprendizaje automático

Guillermo Molero-Castillo

guillermo.molero@ingenieria.unam.edu

Diciembre, 2020

Aprender

Para adquirir conocimientos o comprensión mediante el análisis o la experiencia.


Aprendizaje automático

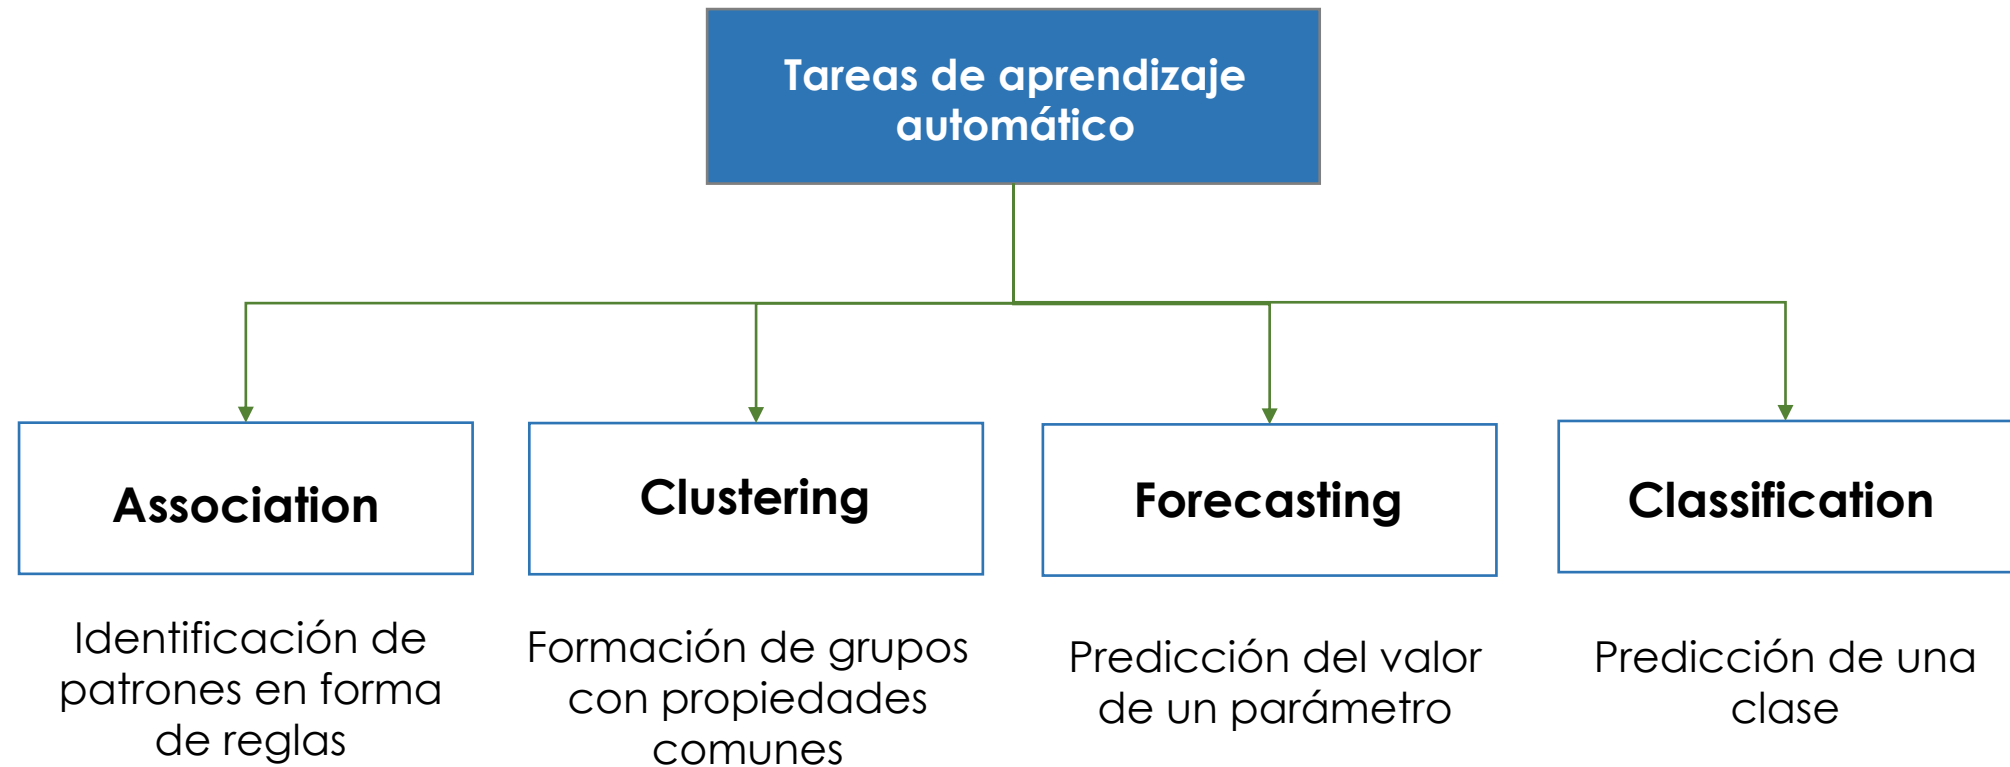
- Es aprender automáticamente a partir de los datos, a través de un proceso de inferencia, ajuste de modelo o aprendizaje de ejemplos (reconocimiento de rostros o personas).
- Es ideal para áreas con gran cantidad de datos en ausencia de una teoría general.
- La extracción automática de información es útil mediante la construcción de buenos modelos inferenciales.

Contexto

En la actualidad, los modelos de pronóstico se han vuelto predominantes. En diferentes disciplinas se trata de aplicar los algoritmos de aprendizaje automático:

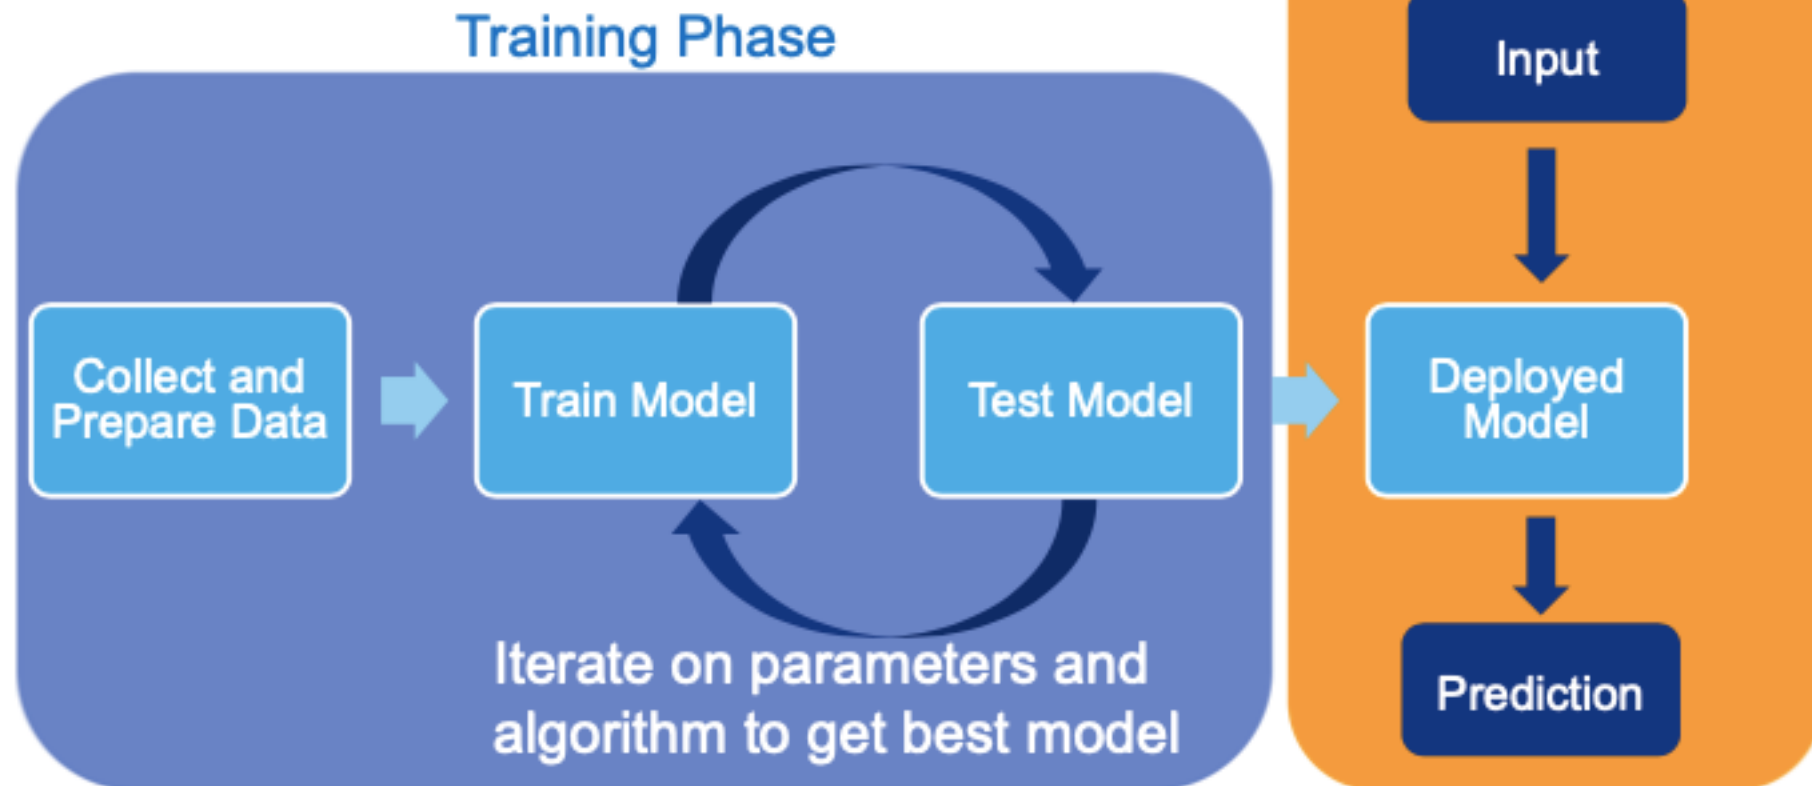
- Los economistas para predecir los precios del mercado, obtener ganancias.
- Los médicos para diagnóstico, por ejemplo, clasificar si un tumor es maligno o benigno.
- Los meteorólogos para predecir el clima.
- Los reclutadores de recursos humanos para verificar si el solicitante cumple con los criterios mínimos para el trabajo.
- Entre otros.





Contexto

1. Training Phase
2. Inference Phase



Algoritmos

La predicción es importante, ayuda a automatizar actividades. Sin embargo, solo dice lo que sucederá, pero no lo que se debería hacer.

- Linear regression / Logistic regression
- Nearest Neighbor (kNN)
- Decision trees
- Support vector machines
- Artificial Neural Networks
- Bayesian methods
- ...

Los diferentes algoritmos tienen diferentes fortalezas y debilidades.
Se debe seleccionar el enfoque de predicción que sea adecuado para el problema.

Regresión lineal


Regresión lineal

La regresión lineal es un algoritmo básico (rudimentario) de aprendizaje supervisado, cuyo objetivo es calcular una ecuación que minimiza la distancia entre la línea ajustada (recta) y todos los puntos de datos.

El propósito es proporcionar una base para desarrollar y aprender otros algoritmos de ML.

F1	F2	F3	F4	Class (Y)
1	0	1	1	0.5
0	1	1	0	2
1	0	1	0	0
0	1	0	1	1.2

Y
Es la variable
dependiente
(output)



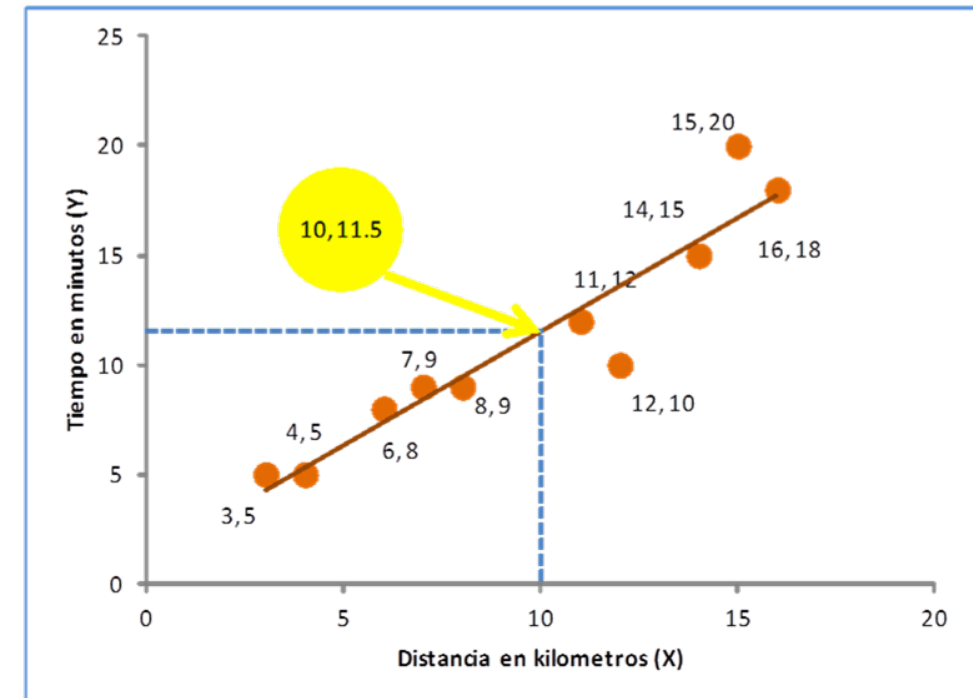
X
Es la variable independiente (input)

Regresión lineal

La regresión según el número de variables son:


- Si se tiene dos variables (2 dimensiones) se trata de un problema de **regresión lineal simple**.
- Si se tiene más de dos variables se trata de un problema de **regresión lineal múltiple**.

Se utiliza para pronosticar una variable dependiente (clase): Y , en función de una o más variables independientes: $X_1, X_2, X_3, \dots, X_n$



Regresión lineal


- Un diagrama de dispersión ofrece una aproximación sobre el **tipo de relación** entre las variables.
- Con base en los datos, se traza una recta (línea) que modele mejor los puntos.
- A esto se conoce como la recta de mejor ajuste.




El patrón sugiere una relación positiva

Tipos de relación


Relación lineal positiva




Relación lineal negativa



Relación no lineal



Ausencia de relación



Regresión lineal simple

Regresión lineal simple

En una regresión lineal simple se evalúa una sola variable independiente (X), cuya ecuación lineal es:

1. Dada una entrada **X**, se calcula una salida **Y**: $Y = a + bX + u$
2. Para esto se estiman los parámetros **a** y **b** (conocidos como coeficientes)


donde:

- **a** es el intercepto (corta el eje Y).

$$a = \bar{y} - b\bar{x}$$

- **b** es la pendiente de la recta.

$$b = \frac{\text{Cov}(x, y)}{S_x^2}$$



Regresión lineal múltiple


Regresión lineal múltiple

En una **regresión lineal múltiple** se evalúa dos o más variables independientes (X_1, X_2, \dots, X_n).

1. Se ajusta una regresión lineal: $Y = a + b_1X_1 + b_2X_2 \dots + b_nX_n + u$

Donde:


- a es el intercepto (corta el eje Y).
- b_1, b_2, \dots, b_n son valores de la pendiente.



Residuo

Residuo

- Al ajustar los datos en el hiperplano (recta) que "pasa por" los puntos, puede existir una diferencia entre el punto pronosticado y la observación real.
- A esto se conoce como **residuo**.



Residuo


La diferencia entre $Y - \hat{Y}$ es el error estimado.

- Y es el valor real.
- \hat{Y} es el valor pronosticado: $\hat{Y}_i = a + bX_i$

$$\text{Suma del error cuadrático} = SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

A partir de **SSE** se calcula el **residuo** (**SEE**, error estandar), que mide la dispersión de los valores observados alrededor de la línea de regresión:

$$\text{Residuo} = \text{Error residual} = SEE = \sqrt{\frac{SSE}{n-2}} = \sqrt{\frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n-2}}$$


$$Y = a + b_i X_i + u$$

Bondad de ajuste

Bondad de ajuste

- La bondad de ajuste, conocido también como coeficiente de determinación (R^2 o R2 Score), se utiliza para medir la precisión del modelo de regresión.
- Indica qué tan cerca están los datos de la línea de regresión ajustada. Representa un porcentaje entre 0 y 1.

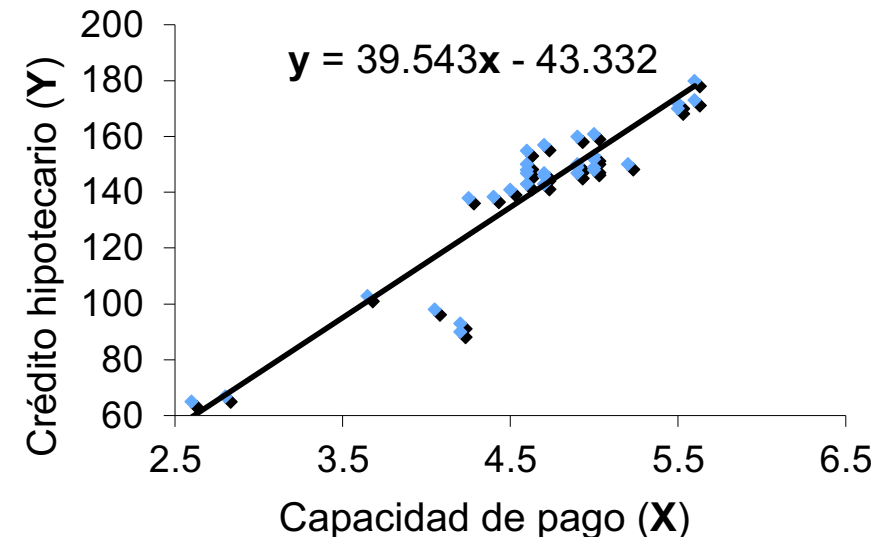
$$\bar{R}^2 = 1 - \frac{N - 1}{N - k - 1} [1 - R^2]$$

Número de variables independientes

- 0 cuando las variables son independientes.
- 1 cuando las variables tienen una relación perfecta.

Por ejemplo, Si R^2 es 0.87, indica:


- Si se conoce la **capacidad de pago** (ingresos), entonces se puede lograr, con un 87%, el pronóstico de algún **crédito hipotecario**.



Bondad de ajuste

Limitaciones de R-cuadrado

- Con R-cuadrado no se puede determinar si las estimaciones de los coeficientes están sesgadas.
- R cuadrado puede tener un valor bajo para un buen modelo, o alto para otro que no se ajusta a los datos.



Ejemplo 1

Ejemplo

Sean dos variables: Meses del año y Cantidad (coches vendidos)

Nro	Mes_X	Cantidad_Y
1	1	132
2	2	170
3	3	230
4	4	205
5	5	260
6	6	302
7	7	330
8	8	360
9	9	480
10	10	440
11	11	485
12	12	540
13		
14		
15		
	6.50	327.83

$$Y_i = a + bX_i + u$$

Variable a predecir
Variable dependiente
Clase

Intercepto
Punto de corte
Alfa

Pendiente
Coeficiente

Variable independiente
Variable explicativa
Predictora

Residuo
Error

Ejemplo

$$Y_i = a + bX_i + u$$

Solución

Nro			1	2	3
	Mes_X	Cantidad_Y	x (varianza)	x*Cantidad_Y	x²
1	1	132	-5.50	-726	30.25
2	2	170	-4.50	-765	20.25
3	3	230	-3.50	-805	12.25
4	4	205	-2.50	-513	6.25
5	5	260	-1.50	-390	2.25
6	6	302	-0.50	-151	0.25
7	7	330	0.50	165	0.25
8	8	360	1.50	540	2.25
9	9	480	2.50	1200	6.25
10	10	440	3.50	1540	12.25
11	11	485	4.50	2183	20.25
12	12	540	5.50	2970	30.25
13					
14					
15					
	6.50	327.83		5248	143

Ejemplo

$$Y_i = a + bX_i + u$$

Solución

			1	2	3	
Nro	Mes_X	Cantidad_Y	x (varianza)	x*Cantidad_Y	x ²	
1	1	132	-5.50	-726	30.25	
2	2	170	-4.50	-765	20.25	
3	3	230	-3.50	-805	12.25	
4	4	205	-2.50	-513	6.25	
5	5	260	-1.50	-390	2.25	
6	6	302	-0.50	-151	0.25	
7	7	330	0.50	165	0.25	
8	8	360	1.50	540	2.25	
9	9	480	2.50	1200	6.25	
10	10	440	3.50	1540	12.25	
11	11	485	4.50	2183	20.25	
12	12	540	5.50	2970	30.25	
13						
14						
15						
	6.50	327.83		5248	143	

4 Pendiente (b)

$$b = \frac{\text{Cov}(x, y)}{S_x^2}$$

$$b = \frac{\sum(x * \text{Cantidad}_Y)}{\sum x^2}$$

$$b = 5248 / 143$$

$$b = 36.7$$

Ejemplo

Solución

$$Y_i = a + bX_i + u$$

			1	2	3
Nro	Mes_X	Cantidad_Y	x (varianza)	x*Cantidad_Y	x ²
1	1	132	-5.50	-726	30.25
2	2	170	-4.50	-765	20.25
3	3	230	-3.50	-805	12.25
4	4	205	-2.50	-513	6.25
5	5	260	-1.50	-390	2.25
6	6	302	-0.50	-151	0.25
7	7	330	0.50	165	0.25
8	8	360	1.50	540	2.25
9	9	480	2.50	1200	6.25
10	10	440	3.50	1540	12.25
11	11	485	4.50	2183	20.25
12	12	540	5.50	2970	30.25
13					
14					
15					
	6.50	327.83		5248	143

4 Pendiente: b

$$b = 5248 / 143$$

$$b = 36.7$$

5 Intercepto: a

$$Y = a + bX$$

$$a = \bar{y} - b\bar{x}$$

$$a = 327.83 - (36.7 * 6.5)$$

$$a = 327.83 - 238.55$$

$$a = 89.29$$

Ejemplo

$$Y_i = a + bX_i + u$$

Solución

Nro	Mes_X	Cantidad_Y	x (varianza)	x*Cantidad_Y	x ²	Ŷ (pronóstico)
1	1	132	-5.50	-726	30.25	125.99
2	2	170	-4.50	-765	20.25	162.69
3	3	230	-3.50	-805	12.25	199.39
4	4	205	-2.50	-513	6.25	236.09
5	5	260	-1.50	-390	2.25	272.78
6	6	302	-0.50	-151	0.25	309.48
7	7	330	0.50	165	0.25	346.18
8	8	360	1.50	540	2.25	382.88
9	9	480	2.50	1200	6.25	419.58
10	10	440	3.50	1540	12.25	456.28
11	11	485	4.50	2183	20.25	492.98
12	12	540	5.50	2970	30.25	529.68
13						
14						
15						
	6.50	327.83		5248	143	

6 Pronóstico: Ŷ

$$Y_i = a + bX_i$$

$$\hat{Y}_1 = 89.29 + 36.7(1)$$

$$\hat{Y}_1 = 89.29 + 36.7$$

$$\hat{Y}_1 = 125.99$$

$$\hat{Y}_2 = 89.29 + 36.69(2)$$

$$\hat{Y}_2 = 89.29 + 73.38$$

$$\hat{Y}_2 = 162.69$$

...

Ejemplo

$$Y_i = a + bX_i + u$$

Solución

Nro	Mes_X	Cantidad_Y	x (varianza)	x*Cantidad_Y	x ²	Ŷ (pronóstico)	(Y-Ŷ) ²
1	1	132	-5.50	-726	30.25	125.99	36.15
2	2	170	-4.50	-765	20.25	162.69	53.49
3	3	230	-3.50	-805	12.25	199.39	937.23
4	4	205	-2.50	-513	6.25	236.09	966.28
5	5	260	-1.50	-390	2.25	272.78	163.44
6	6	302	-0.50	-151	0.25	309.48	56.01
7	7	330	0.50	165	0.25	346.18	261.89
8	8	360	1.50	540	2.25	382.88	523.60
9	9	480	2.50	1200	6.25	419.58	3650.38
10	10	440	3.50	1540	12.25	456.28	265.07
11	11	485	4.50	2183	20.25	492.98	63.68
12	12	540	5.50	2970	30.25	529.68	106.51
13							
14							
15							
	6.50	327.83		5248	143		7083.74

7 Error cuadrático

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$SSE_1 = (132 - 125.99)^2$$

$$SSE_1 = (6.01)^2$$

$$SSE_1 = 36.15$$

$$SSE_2 = (170 - 162.69)^2$$

$$SSE_2 = (7.31)^2$$

$$SSE_2 = 53.49$$

Ejemplo

$$Y_i = a + bX_i + u$$

Solución

Nro	Mes_X	Cantidad_Y	x (varianza)	x*Cantidad_Y	x ²	Ŷ (pronóstico)	(Y-Ŷ) ²
1	1	132	-5.50	-726	30.25	125.99	36.15
2	2	170	-4.50	-765	20.25	162.69	53.49
3	3	230	-3.50	-805	12.25	199.39	937.23
4	4	205	-2.50	-513	6.25	236.09	966.28
5	5	260	-1.50	-390	2.25	272.78	163.44
6	6	302	-0.50	-151	0.25	309.48	56.01
7	7	330	0.50	165	0.25	346.18	261.89
8	8	360	1.50	540	2.25	382.88	523.60
9	9	480	2.50	1200	6.25	419.58	3650.38
10	10	440	3.50	1540	12.25	456.28	265.07
11	11	485	4.50	2183	20.25	492.98	63.68
12	12	540	5.50	2970	30.25	529.68	106.51
13							
14							
15							
	6.50	327.83		5248	143		7083.74

8 Error residual

$$SEE = \sqrt{\frac{SSE}{n - 2}}$$

$$SEE = \sqrt{\frac{7083.74}{12 - 2}}$$

$$SEE = 26.62$$

Ejemplo

Función de estimación:

$$Y_i = a + bX_i + u \quad Y_i = 89.29 + 36.7X_i + 26.62$$


Pronóstico de nuevos casos: \hat{Y}

$$\hat{Y}_{13} = 89.29 + 36.7(13) + 26.62 = 89.29 + 477.1 + 26.62 = 593.01$$

$$\hat{Y}_{14} = 89.29 + 36.7(14) + 26.62 = 89.29 + 513.8 + 26.62 = 629.71$$

$$\hat{Y}_{15} = 89.29 + 36.7(15) + 26.62 = 89.29 + 550.5 + 26.62 = 666.41$$

Nro	Mes_X	Cantidad_Y
1	1	132
2	2	170
3	3	230
4	4	205
5	5	260
6	6	302
7	7	330
8	8	360
9	9	480
10	10	440
11	11	485
12	12	540
13	13	593
14	14	630
15	15	666



Ejemplo

9

Bondad de ajuste

$$SEE = \sqrt{\frac{SSE}{n-2}}$$

Error estandar del residuo

Pendiente (b)

Intercepto (a)

R (coef. Correl)

R cuadrado

Total Observaciones

R cuadrado ajustado

26.62

36.70

89.29

0.98

0.96

12

0.96

$$\text{Cantidad_Y} = 89.29 + 36.7 \text{Mes_X} + 26.62$$

$$Y_i = a + bX_i + u_i$$

$$\bar{R}^2 = 1 - \frac{N-1}{N-k-1} [1 - R^2]$$

Número de variables independientes

$$\bar{R}^2 = 1 - \frac{N-1}{N-k-1} [1 - R^2]$$

$$\bar{R}^2 = 1 - \frac{12-1}{12-1-1} [1 - 0.96]$$

$$\bar{R}^2 = 1 - 0.044$$

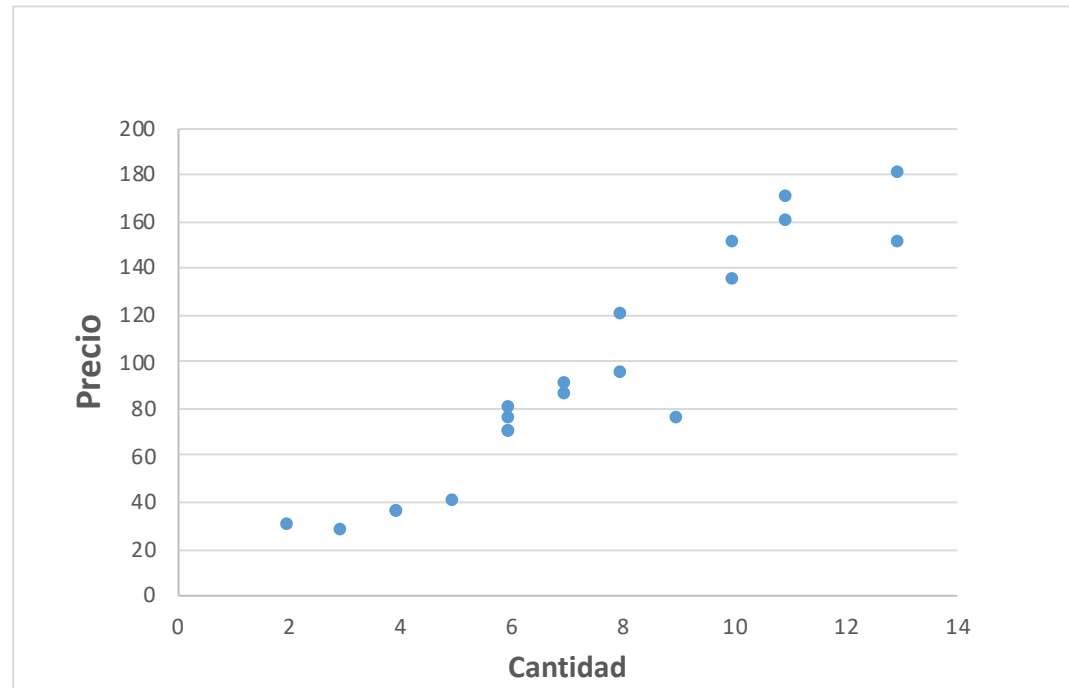
$$\bar{R}^2 = 0.956$$

Ejemplo 2

Ejemplo 2

Sean dos variables: Precio y Cantidad (productos)

Nro	Precio	Cantidad
1	75	9
2	170	11
3	70	6
4	35	4
5	85	7
6	120	8
7	160	11
8	70	6
9	40	5
10	80	6
11	150	10
12	95	8
13	30	2
14	27	3
15	90	7
16	180	13
17	135	10
18	35	4
19	75	6
20	150	13
93.60		7.45



Ejemplo 2

Solución

			1	2	3	
Nro	Precio	Cantidad	vP	vP*Cantidad	vP ²	Ŷ (Pronóstico)
1	75	9	-18.60	-167	345.96	6.32
2	170	11	76.40	840	5836.96	12.08
3	70	6	-23.60	-142	556.96	6.02
4	35	4	-58.60	-234	3433.96	3.90
5	85	7	-8.60	-60	73.96	6.93
6	120	8	26.40	211	696.96	9.05
7	160	11	66.40	730	4408.96	11.47
8	70	6	-23.60	-142	556.96	6.02
9	40	5	-53.60	-268	2872.96	4.20
10	80	6	-13.60	-82	184.96	6.63
11	150	10	56.40	564	3180.96	10.87
12	95	8	1.40	11	1.96	7.53
13	30	2	-63.60	-127	4044.96	3.60
14	27	3	-66.60	-200	4435.56	3.41
15	90	7	-3.60	-25	12.96	7.23
16	180	13	86.40	1123	7464.96	12.68
17	135	10	41.40	414	1713.96	9.96
18	35	4	-58.60	-234	3433.96	3.90
19	75	6	-18.60	-112	345.96	6.32
20	150	13	56.40	733.20	3180.96	10.87
	93.60	7.45		2835	46785	

4 Pendiente: b

$$b = \text{Suma}(vP * \text{Cantidad}) / \text{Suma}(vP^2)$$

$$b = 2835 / 46785$$

$$b = 0.06$$

5 Intercepto: a

$$a = \text{Prom}(\text{Cantidad}) - (b * \text{Prom}(\text{Precio}))$$

$$a = 7.45 - (0.06 * 93.6)$$

$$a = 7.45 - 5.616$$

$$a = 1.78$$

6 Pronóstico: \hat{Y}

$$\hat{Y}_1 = 1.78 + 0.06 (75)$$

$$\hat{Y}_1 = 1.78 + 4.5$$

$$\hat{Y}_1 = 6.32$$

Ejemplo 2

Solución

Nro	Precio	Cantidad	\hat{Y} (Pronóstico)	$(Y - \hat{Y})^2$
1	75	9	6.32	7.17
2	170	11	12.08	1.16
3	70	6	6.02	0.00
4	35	4	3.90	0.01
5	85	7	6.93	0.01
6	120	8	9.05	1.10
7	160	11	11.47	0.22
8	70	6	6.02	0.00
9	40	5	4.20	0.64
10	80	6	6.63	0.39
11	150	10	10.87	0.75
12	95	8	7.53	0.22
13	30	2	3.60	2.55
14	27	3	3.41	0.17
15	90	7	7.23	0.05
16	180	13	12.68	0.10
17	135	10	9.96	0.00
18	35	4	3.90	0.01
19	75	6	6.32	0.10
20	150	13	10.87	4.55
	93.60	7.45		19.21

7

Error cuadrático: $(Y - \hat{Y})^2$

$$SSE = (Cantidad - \hat{Y})^2$$

$$SSE_1 = (9 - 6.32)^2$$

$$SSE_1 = 7.17$$

...

$$SSE = \sum_{i=1}^n [Y_i - \hat{Y}_i]^2 \quad \text{SSE} = 19.21$$

8

Error residual

$$SEE = \sqrt{\frac{SSE}{n - 2}}$$

$$SEE = \sqrt{\frac{19.21}{20 - 2}} = \sqrt{\frac{19.21}{18}} = 1.03$$

Ejemplo 2

Función de estimación: $Y_i = 1.78 + 0.06X_i + 1.03$

Nro	Precio	Cantidad
21	82	8
22	102	9
23	162	13
24	48	6
25	64	7

Pronóstico de nuevos casos: \hat{Y}

$$\hat{Y}_{21} = 1.78 + 0.06(82) + 1.03 = 7.73 = 8$$

$$\hat{Y}_{22} = 1.78 + 0.06(102) + 1.03 = 8.93 = 9$$

$$\hat{Y}_{23} = 1.78 + 0.06(162) + 1.03 = 12.53 = 13$$

$$\hat{Y}_{24} = 1.78 + 0.06(48) + 1.03 = 5.69 = 6$$

$$\hat{Y}_{25} = 1.78 + 0.06(64) + 1.03 = 6.65 = 7$$

Ejemplo 2

9

Bondad de ajuste

$$SEE = \sqrt{\frac{SSE}{n-2}}$$

Error estandar del residuo

Pendiente (b)

Intercepto (a)

R (coef. Correl)

R cuadrado

Total Observaciones

R cuadrado ajustado

1.03

0.06

1.78

0.95

0.90

20

0.89

Cantidad = 1.78 + 0.06 Precio - 1.03

$$Y_i = a + bX_i + u_i$$

$$\bar{R}^2 = 1 - \frac{N-1}{N-k-1} [1 - R^2]$$

Número de variables independientes

$$\bar{R}^2 = 1 - \frac{N-1}{N-k-1} [1 - R^2]$$

$$\bar{R}^2 = 1 - \frac{20-1}{20-1-1} [1 - 0.90]$$

$$\bar{R}^2 = 1 - 0.1055$$


$$\bar{R}^2 = 0.89$$

Consideraciones

La regresión lineal es un algoritmo útil. Sin embargo, obliga a ajustar los datos en forma de línea, que en ocasiones no encaja.

- Pronóstico de ventas.
- Pronóstico del consumo eléctrico.
- Pronóstico de la demanda de productos y servicios.
- Estimación de precios.
- Pronóstico de la bolsa de valores.
- Entre otros.

Cuando el problema incluye una no linealidad, entonces se necesita emplear otros algoritmos.



Consideraciones

Una solución a la no linealidad sería usar polinomios, pero sigue siendo un problema de regresión.

Entonces, ¿qué tipo de funciones se pueden usar?

Polinomial: $\hat{y} = a + b_1x + b_2x^2 + u$

$$\hat{y} = a + b_1x + b_2x^2 + b_3x^3 + u$$

Exponencial: $\hat{y} = a + e^{bx}$

Logarítmico: $\hat{y} = a + b \log x$


Sigmoide: $\hat{y} = \frac{1}{1 + e^{-(a+bX)}}$

Gaussiana: $\hat{y} = \frac{(x - \mu_j)}{2\sigma_j^2}$

Caso práctico

Caso de estudio

- Se tiene 4 mediciones de registros geofísicos: RC1, RC2, RC3 y RC4
- Se desea obtener el pronóstico (valores integrados) para estas 4 mediciones.



- RC1 = Registro Neutrón
 - RC2 = Registro Sónico
 - RC3 = Registro Densidad-Neutrón
 - RC4 = Registro Densidad (corregido por arcilla)
-
- Para la toma de registros se cuenta con cables electromecánicos, sensores, dispositivos eléctricos y sistemas computarizados.
 - Se procesan los datos a través de los sensores, para luego ser enviados a la superficie por medio del cable.

Caso de estudio

```
RegGeo <- read.table("/Users/guille/Documents/1 FI-UNAM/1 Cursos/2021-1/1 IA2021-1/2  
CasosPracticos/5 RLineal/RGeofisicos.txt", header=TRUE, sep="\t")
```


RegGeo

	Profundidad	RC1	RC2	RC3	RC4
1	5660.0	0.7779242	0.8140291	0.6756982	0.7578417
2	5660.5	0.7962395	0.8131670	0.7486699	0.7938719
3	5661.0	0.7692308	0.7975620	0.7022851	0.7483621
4	5661.5	0.7647744	0.7903653	0.6802887	0.7384512
5	5662.0	0.7738128	0.7881841	0.7002481	0.7184618
6	5662.5	0.7956272	0.7988501	0.7534721	0.7775373
7	5663.0	0.8021554	0.8377173	0.7854410	0.8079569
8	5663.5	0.7978784	0.8338511	0.7568469	0.7796415
9	5664.0	0.7772059	0.8131166	0.7187127	0.7614542
10	5664.5	0.7886036	0.8200411	0.7295821	0.7656005
11	5665.0	0.7769245	0.8159172	0.7373500	0.7886884
12	5665.5	0.7690031	0.7979401	0.7247360	0.7796748
13	5666.0	0.7553049	0.8151496	0.6791887	0.7629721
14	5666.5	0.7460951	0.8047134	0.6596015	0.7546896
15	5667.0	0.7570502	0.7931801	0.6513744	0.7483805
16	5667.5	0.7441865	0.7864764	0.6124304	0.6880620

Caso de estudio

- Variables independientes: Profundidad, RC1, RC2 y RC3
- Variable dependiente: RC4 ([Registro Densidad -corregido por arcilla-](#))

```
library(Rcmdr)
with(RegGeo, lineplot(Profundidad, RC1, RC2, RC3, RC4))
```



Caso de estudio

```
Regresion <- lm(RegGeo, formula = RC4 ~ Profundidad+RC1+RC2+RC3)
```

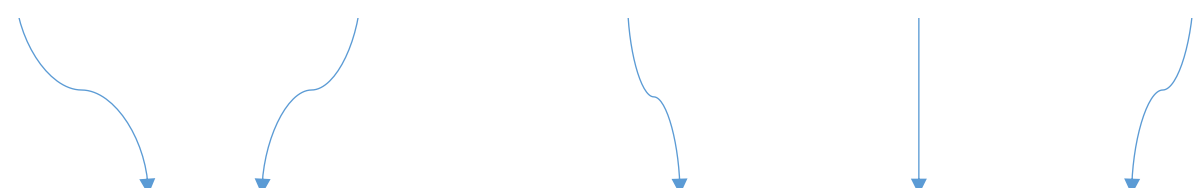
Regresion

Call:

```
lm(formula = RC4 ~ Profundidad + RC1 + RC2 + RC3, data = RegGeo)
```

Coefficients:

(Intercept)	Profundidad	RC1	RC2	RC3
2.624e-01	-7.506e-05	5.066e-01	2.275e-01	4.891e-01


$$\widehat{RC4} = a + b_1 \text{Profundidad} + b_2 \text{RC1} + b_3 \text{RC2} + b_4 \text{RC3} + u$$

Caso de estudio

summary(Regresion)

```
Coefficients:
      Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.624e-01  7.640e+00   0.034 0.972813
Profundidad -7.506e-05  1.320e-03  -0.057 0.954992
RC1          5.066e-01  2.296e-01   2.207 0.034397 *
RC2          2.275e-01  2.171e-01   1.048 0.302269
RC3          4.891e-01  1.145e-01   4.272 0.000155 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02097 on 33 degrees of freedom
Multiple R-squared:  0.8581, Adjusted R-squared:  0.8409
F-statistic: 49.9 on 4 and 33 DF, p-value: 1.539e-13
```

```
Coefficients:
      Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.26237022  7.64044786   0.034 0.972813
Profundidad -0.00007506  0.00131985  -0.057 0.954992
RC1          0.50661905  0.22957422   2.207 0.034397 *
RC2          0.22747126  0.21705964   1.048 0.302269
RC3          0.48909133  0.11449548   4.272 0.000155 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02097 on 33 degrees of freedom
Multiple R-squared:  0.8581, Adjusted R-squared:  0.8409
F-statistic: 49.9 on 4 and 33 DF, p-value: 1.539e-13
```

$$\widehat{RC4} = a + b_1 \text{Profundidad} + b_2 \text{RC1} + b_3 \text{RC2} + b_4 \text{RC3} + u$$

$$\widehat{RC4} = 0.2623 - 0.000075 \text{Profundidad} + 0.5066 \text{RC1} + 0.2274 \text{RC2} + 0.4890 \text{RC3} + 0.02097$$

Caso de estudio

```
Pronostico <- predict(Regresion, type = "response", newdata = RegGeo[, c("Profundidad", "RC1", "RC2",  
"RC3")])
```

Pronostico

$$\widehat{RC4} = 0.2623 - 0.000075\text{Profundidad} + 0.5066\text{RC1} + 0.2274\text{RC2} + 0.4890\text{RC3} + 0.02097$$

1	2	3	4	5	6	7	8	9	10	11	12	13
0.7472942	0.7920293	0.7520726	0.7373820	0.7511894	0.7906610	0.8184077	0.8013388	0.7674605	0.7800886	0.7769953	0.7626860	0.7373466
14	15	16	17	18	19	20	21	22	23	24	25	26
0.7206894	0.7195546	0.6924280	0.7269750	0.7446542	0.7199351	0.6672274	0.6903277	0.7000343	0.6800535	0.6777213	0.6594727	0.6872664
27	28	29	30	31	32	33	34	35	36	37	38	
0.6635396	0.6779189	0.6983861	0.6312838	0.6751625	0.6957009	0.6951390	0.6845189	0.6673696	0.6512601	0.6482442	0.6553729	

Caso de estudio

`write.csv(cbind(RegGeo, Pronostico), file="/Users/guille/Documents/1 FI-UNAM/1 Cursos/2021-1/1 IA2021-1/2 CasosPracticos/5 RLineal/Resultados.csv", row.names=FALSE)`

Resultados					
Profundidad	RC1	RC2	RC3	RC4	Pronostico
5660	0.77792425	0.814029063	0.67569817	0.757841697	0.747294237159165
5660.5	0.796239499	0.81316698	0.748669946	0.793871855	0.792029326006498
5661	0.769230786	0.797562036	0.702285088	0.748362073	0.752072559621215
5661.5	0.76477436	0.790365252	0.680288728	0.738451206	0.737382029266921
5662	0.773812818	0.788184093	0.700248127	0.718461836	0.751189372948178
5662.5	0.79562719	0.798850051	0.753472127	0.777537338	0.79066101602287
5663	0.802155394	0.837717345	0.785440951	0.807956871	0.818407666080092
5663.5	0.797878424	0.833851101	0.756846932	0.779641454	0.801338795826379
5664	0.777205898	0.813116563	0.718712688	0.761454166	0.767460531117542
5664.5	0.788603618	0.820041076	0.729582106	0.765600467	0.780088569588179
5665	0.776924464	0.815917152	0.737349992	0.788688434	0.776995289745656
5665.5	0.769003107	0.797940103	0.724735975	0.77967479	0.762685981567906
5666	0.755304855	0.815149612	0.679188716	0.762972062	0.737346555588098

Caso de estudio

`with(RegGeo, plot(Profundidad, Pronostico, pch=18, col=3, type="b"))`

