



**Universidad Nacional Autónoma de México**  
Facultad de Ingeniería

# **Máquinas de soporte vectorial**

## **(SVM, Support Vector Machines)**

**Guillermo Molero-Castillo**

guillermo.molero@ingenieria.unam.edu

Enero, 2021

## Clasificación

**Binaria:** Cada elemento puede pertenecer a una de dos clases.


$$f: \rightarrow \{-1, 1\}$$

**Multiclase :** Cada elemento puede pertenecer a una de las  $K$  clases.

$$f: \rightarrow \{1, \dots, K\}$$

# Máquinas de soporte vectorial


## Clasificación



Proyección en el plano (vector)


# Máquinas de soporte vectorial

- **SVM**, tal como se entiende actualmente, fue presentado en la conferencia COLT (*COmputational Learnig Theory*) por Vapnik, Boser y Guyon en 1992.
- Posteriormente, fue descrito con mayor detalle en 1995 (Cortes y Vapnik) y 1998 (Vapnik) para pasar de la formulación teórica a su aplicación práctica en problemas reales de reconocimiento de patrones (*pattern recognition*).
- En la actualidad, el interés por este algoritmo no ha dejado de crecer en su aplicación a problemas reales. Se utiliza tanto para clasificación como para pronóstico (regresión).



# Máquinas de soporte vectorial

- Hoy en día, **SVM** constituye un referente en el aprendizaje automático, sobre todo para encontrar la manera óptima de resolver problemas de clasificación.
- Intuitivamente, una SVM es un modelo que representa los puntos en el espacio, separando las clases en dos (espacios) mediante un hiperplano.
- Se busca la **separación máxima posible** entre los puntos más cercanos a cada clase (vectores de soporte).



# Máquinas de soporte vectorial

## Características

- Es un algoritmo de clasificación para datos lineales y no lineales.
- Utiliza un mapeo no lineal para transformar los datos de entrenamiento en una dimensión superior.
- Con la nueva dimensión, se busca el hiperplano de separación lineal óptimo.
- Con un mapeo no lineal apropiado, los datos pueden ser separados por un hiperplano.
- SVM encuentra este hiperplano usando **vectores de soporte** (datos de entrenamiento) para medir los **márgenes de separación**.

# Máquinas de soporte vectorial

## Principales ideas

- **Clasificador de margen máximo (Max-Margin Classifier)**

Formalizar la noción del mejor separador lineal.

- **Multiplicadores de Lagrange (Lagrangian Multipliers)**

Es la manera de convertir un problema de optimización en uno de posible solución.

- **Kernels**

Proyectar los datos en un espacio de dimensiones superiores para hacerlos separables.


- **Complejidad**

Depende de la cantidad de ejemplos de entrenamiento, no de la dimensionalidad del espacio del kernel.

# Máquinas de soporte vectorial

## Fundamentos

Asumiendo un conjunto de datos  $\mathbf{D} (\mathbf{x}_i, y_i)_{i=1\dots n}$  asociados a una etiqueta de clase  $y_i \in \{-1, 1\}$ , separables mediante un hiperplano.





- Pueden existir diversas líneas (hiperplanos) que separan las dos clases, pero se debe encontrar el hiperplano óptimo (maximiza el margen de separación).



# Máquinas de soporte vectorial

## Fundamentos

Para caracterizar al hiperplano separador se utiliza el vector **(w)** y la ordenada al origen **(b)** – constante– ([Recordar la ecuación de un hiperplano en álgebra](#)):




# Máquinas de soporte vectorial

## Vectores de soporte

- El **separador de margen máximo** está determinado por un subconjunto de puntos de datos (vectores de soporte).
- Computacionalmente es útil una pequeña fracción de puntos (vectores de soporte), dado que éstos se utilizan para decidir en qué lado del separador se clasificará cada caso de prueba.


$$Y = \text{sgn}[wx + b > 0] = \begin{cases} +1 & wx + b > 0 \\ -1 & wx + b \leq 0 \end{cases}$$



# Máquinas de soporte vectorial

## Distancia

- Intuitivamente, el mejor hiperplano debe estar situado en la posición más neutra posible con respecto a las clases.
- Se considera los puntos que están en la frontera de la región de decisión, dado que es la zona donde puede haber dudas sobre a qué clase pertenece el elemento.




$d^+$  = la distancia más corta al punto positivo más cercano.  
 $d^-$  = la distancia más corta al punto negativo más cercano.  
El **margin** de un hiperplano de separación es  $d^+ + d^-$ .

# Máquinas de soporte vectorial

## Distancia

La distancia del ejemplo  $x_i$  al separador  $H(\mathbf{w}, b)$  es:  $d = \frac{\mathbf{w}x_i + b}{\|\mathbf{w}\|} = \frac{\pm 1}{\|\mathbf{w}\|}$  longitud euclidiana  $\rightarrow \sqrt{\mathbf{w} \cdot \mathbf{w}}$

El **margen** del separador es la distancia entre los vectores de soporte:  $M = \left| \frac{1}{\|\mathbf{w}\|} - \frac{-1}{\|\mathbf{w}\|} \right| = \frac{2}{\|\mathbf{w}\|}$



# Máquinas de soporte vectorial

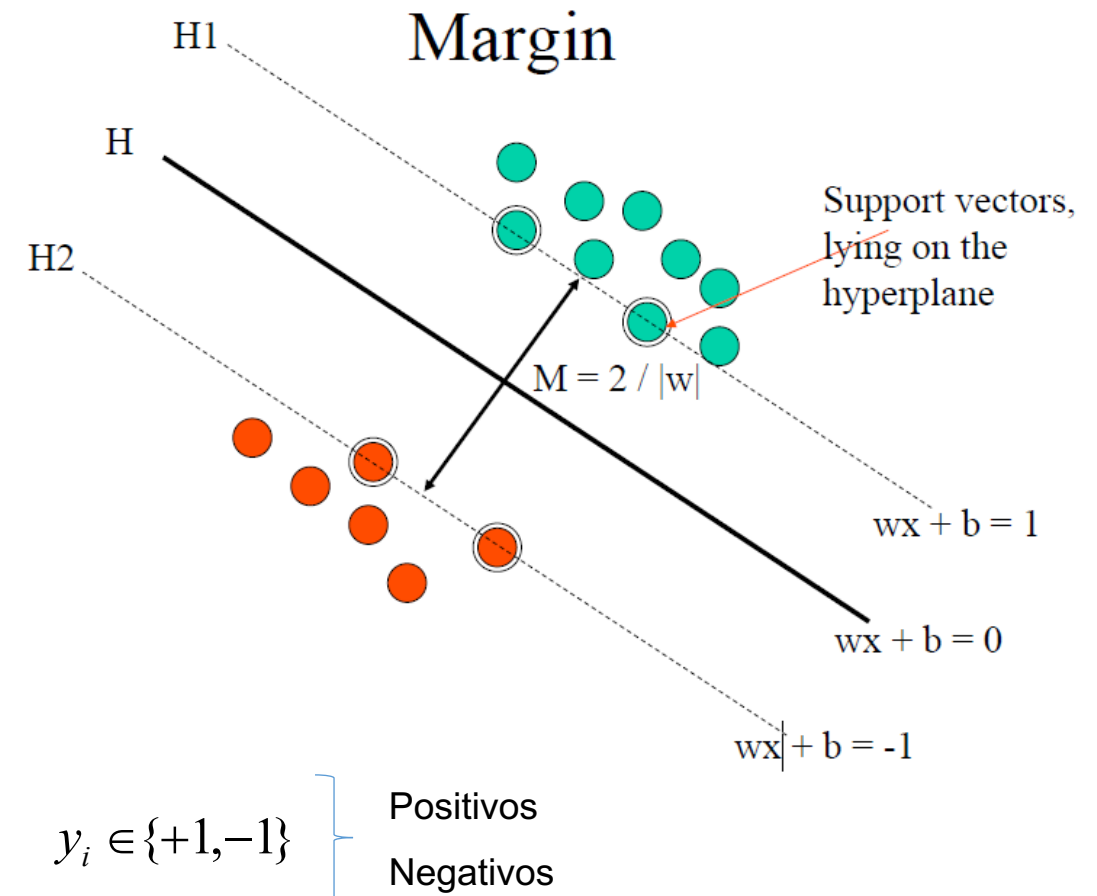
## Formalización

- Todos los hiperplanos de separación están expresados por:

$$\mathbf{w}x + \mathbf{b} = 0$$

donde:  $\mathbf{w} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n\}$  es un vector y  $\mathbf{b}$  una constante.

- El objetivo es encontrar el hiperplano  $f(x) = \mathbf{w}x + \mathbf{b}$  que mejor clasifique los datos (la que minimiza el error de clasificación).
- Entonces, **SVM** busca el hiperplano con el margen más grande, conocido como hiperplano marginal máximo (MMH).



# Máquinas de soporte vectorial

## Formalización

- Sea un conjunto de entrenamiento  $\{(\mathbf{x}_i, y_i)\}_{i=1,\dots,n}$ ,  $\mathbf{x}_i \in \mathbb{R}^d$ ,  $y_i \in \{-1, 1\}$  sea separado por un hiperplano con margen  $\mathbf{M}$ . Entonces para cada elemento del entrenamiento  $(\mathbf{x}_i, y_i)$ :

$$\begin{array}{ll} H_1: & \mathbf{w}\mathbf{x}_i + b \geq +1 \quad \text{si } y_i = +1 \\ H_2: & \mathbf{w}\mathbf{x}_i + b \leq -1 \quad \text{si } y_i = -1 \end{array} \quad \Leftrightarrow \quad y_i(\mathbf{w}\mathbf{x}_i + b) \geq +1$$

- Para cada vector de soporte  $\mathbf{x}_s$ , en la desigualdad anterior, se reescala  $\mathbf{w}$  y  $b$ , obteniéndose la distancia entre cada  $\mathbf{x}_s$  y el hiperplano:

$$d = \frac{y_s(\mathbf{w}\mathbf{x}_s + b)}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

- Entonces el margen se puede expresar mediante  $\mathbf{w}$  y  $b$  como:  $M = 2d = \frac{2}{\|\mathbf{w}\|}$

# Máquinas de soporte vectorial

## Formalización

- Con base a lo anterior, se puede formular el problema de optimización cuadrática:

Para  $\mathbf{w}$  y  $b$ , tales que:  $M = \frac{2}{\|\mathbf{w}\|}$  es maximizada, y para todo  $(\mathbf{x}_i, y_i), i = 1, \dots, n$ :

$$y_i(\mathbf{w}\mathbf{x}_i + b) \geq +1$$

- La necesidad de optimizar una función cuadrática, sujeta a restricciones lineales, es un problema de programación matemática.

# Máquinas de soporte vectorial

## Formalización

- La solución implica construir un problema, donde un **multiplicador de Lagrange**  $\alpha_i$  se asocia con cada restricción de desigualdad en el problema original:

$$\max. \quad L_D(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i x_j$$

donde

$$\sum_{i=1}^n \alpha_i y_i = 0 \quad ; \quad \alpha_i \geq 0$$



# Máquinas de soporte vectorial

## Formalización

- Así, una solución  $\alpha_1 \dots \alpha_n$  al problema dual es:

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \quad b = y_k - \sum \alpha_i y_i \mathbf{x}_i \mathbf{x}_k \quad \text{para cualquier } \alpha_k > 0$$

- Cada  $\alpha_i$  distinto de cero indica que  $\mathbf{x}_i$  es un vector de soporte. Entonces, la función de clasificación sería:

$$f(\mathbf{x}) = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \mathbf{x} + b$$

# Máquinas de soporte vectorial

## Kernels

- Son útiles en problemas de separación de clases.
- Se mapean los datos en un mejor espacio de representación por una determinada función, denominada **kernel**.
- Los **kernel** comunes son:

Linear

$$K(x, y) = x \cdot y$$

Sigmoid

$$K(x, y) = \tanh(ax \cdot y + b)$$

Polynomial

$$K(x, y) = (1 + x \cdot y)^d$$

KMOD

$$K(x, y) = a \left[ \exp \left( \frac{\gamma}{\|x - y\|^2 + \sigma^2} \right) - 1 \right]$$

RBF

$$K(x, y) = \exp(-a\|x - y\|^2)$$


Exponential RBF

$$K(x, y) = \exp(-a\|x - y\|)$$

# Máquinas de soporte vectorial

## Kernels

Las funciones polinómicas y las funciones de base radial (RBF) pueden ser útiles para separar los datos, aún no siendo separables linealmente.



# Máquinas de soporte vectorial

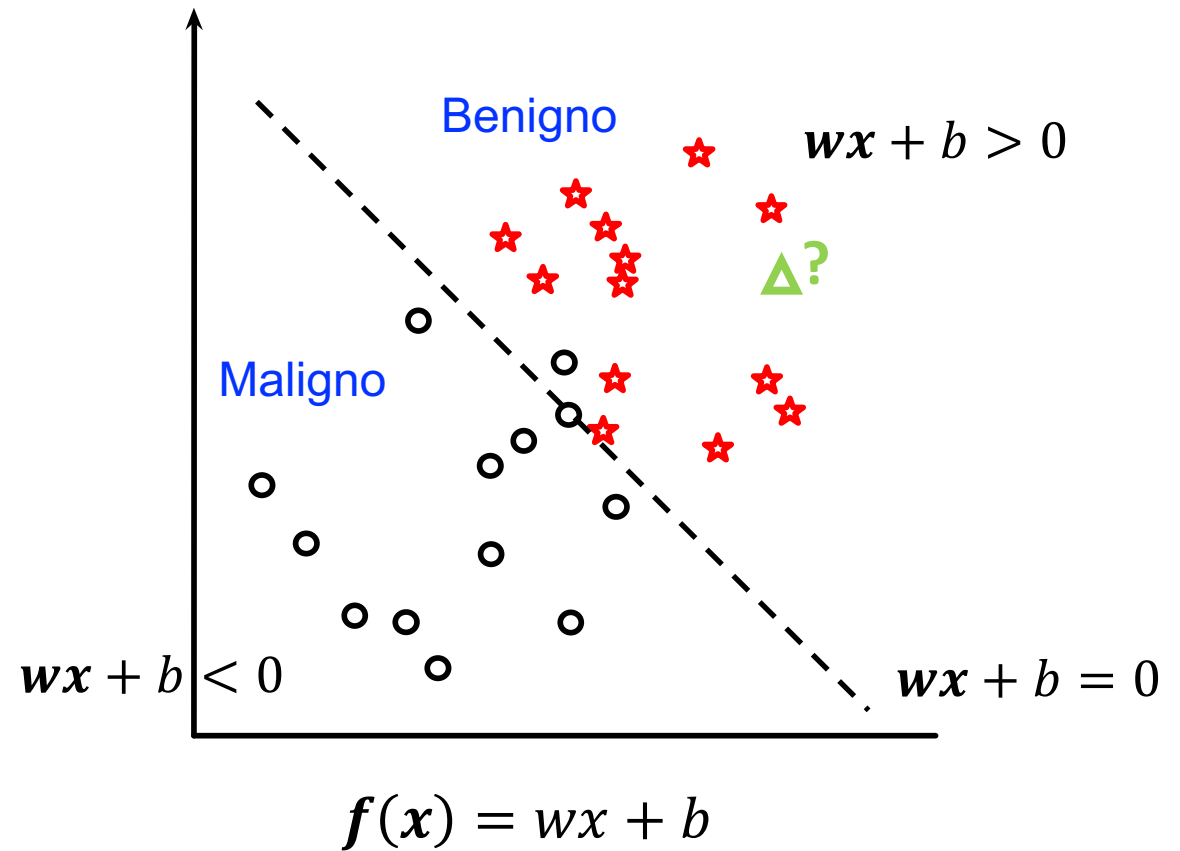

## Consideraciones

- Las SVM se encuentran actualmente entre los algoritmos que mejor desempeño tienen en problemas de clasificación.
- Se pueden aplicar a tipos de datos complejos, más allá de los vectores de características, mediante varios tipos de funciones kernel.
- Los algoritmos de optimización más populares para SVM utilizan un proceso de descomposición, como los multiplicadores de Lagrange.
- El ajuste de las SVM sigue siendo un arte negro: la selección de un kernel y parámetros específicos generalmente se hace de manera prueba y error.

# Máquinas de soporte vectorial

## Ejemplo

$$X = [x_1, x_1, \dots, x_n] \quad Y$$



# Máquinas de soporte vectorial

## Regresión Logística

Exactitud 0.9298245614035088					
	precision	recall	f1-score	support	
0	0.95	0.87	0.91	45	
1	0.92	0.97	0.94	69	
accuracy			0.93	114	
macro avg	0.93	0.92	0.93	114	
weighted avg	0.93	0.93	0.93	114	

# Máquinas de soporte vectorial

## SVM Lineal



```
#Se declara el tipo de kernel  
ModeloSVM_1 = SVC(kernel='linear')
```

```
Exactitud 0.9210526315789473
```

	precision	recall	f1-score	support
-1	0.97	0.82	0.89	45
1	0.89	0.99	0.94	69
accuracy			0.92	114
macro avg	0.93	0.90	0.91	114
weighted avg	0.93	0.92	0.92	114

```
Elementos de validación: 114
```

# Máquinas de soporte vectorial

## SVM RBF



```
#Se declara el tipo de kernel  
ModeloSVM_2 = SVC(kernel='rbf')
```

Exactitud 0.8947368421052632

	precision	recall	f1-score	support
-1	0.95	0.78	0.85	45
1	0.87	0.97	0.92	69
accuracy			0.89	114
macro avg	0.91	0.87	0.89	114
weighted avg	0.90	0.89	0.89	114

Elementos de validación: 114



# Máquinas de soporte vectorial

## SVM RBF



```
#Se declara el tipo de kernel  
ModeloSVM_3 = SVC(kernel='sigmoid')
```

Exactitud 0.45614035087719296

	precision	recall	f1-score	support
-1	0.05	0.02	0.03	45
1	0.54	0.74	0.62	69
accuracy			0.46	114
macro avg	0.29	0.38	0.33	114
weighted avg	0.35	0.46	0.39	114

Elementos de validación: 114